

RÉPONSES DÉTAILLÉES AUX 11 QUESTIONS DU PROJET

Projet Deep Learning - Classification de visages avec équité

Erwan Bretécher et Sivakar Sriranjani

Table des matières

1	Question 1 : Architecture utilisée	3
2	Question 2 : Nombre de convolutions	4
3	Question 3 : Gestion de l'over-fitting	5
4	Question 4 : Asymétrie de la base d'apprentissage	6
5	Question 5 : Labels bruités	7
6	Question 6 : Attribution du label	8
7	Question 7 : Problèmes d'équité	9
8	Question 8 : Caractéristiques softbio	10
9	Question 9 : Modèle pré-appris	11
10	Question 10 : Améliorations possibles	12
11	Question 11 : Signification du label	13

1 Question 1 : Architecture utilisée

QUEL TYPE D'ARCHITECTURE AVEZ-VOUS UTILISÉ, POURQUOI ?

Réponse :

On a utilisé ConvNeXt-Tiny pré-entraîné sur ImageNet, qu'on charge avec timm. Pourquoi ce choix ? Eh bien, ConvNeXt c'est vraiment l'état de l'art actuel pour la classification d'images. C'est une architecture moderne qui utilise des convolutions depthwise, et ça marche mieux que les ResNet classiques qu'on utilisait avant. Comme il est déjà pré-entraîné sur ImageNet, on peut faire du transfer learning efficacement. Et niveau taille, ça colle bien avec nos images 80x80 une fois qu'on fait le fine-tuning.

On a aussi testé d'autres trucs plus simples juste pour voir :

- SimpleCNN : 3 blocs de convolution (pour avoir une baseline rapide)
- ResNetSimple : 6 blocs résiduels (performance intermédiaire)

2 Question 2 : Nombre de convolutions

COMBIEN DE CONVOLUTIONS CONTIENT VOTRE ARCHITECTURE, POURQUOI?

Réponse :

ConvNeXt-Tiny a environ 28 blocs de convolution depthwise. En gros, il y a un stem avec 1 bloc de conv 4x4 stride 4, puis 4 stages avec à peu près 27 blocs de convolutions depthwise. La taille des features diminue progressivement : $96 \rightarrow 48 \rightarrow 24 \rightarrow 12 \rightarrow 6 \rightarrow 3$.

Pourquoi 28 blocs ? C'est un compromis qui marche bien pour nos images 80x80. Si on met trop de couches, on perd de l'info sur ces petites images. Mais si on en met pas assez, le modèle arrive pas à capturer les détails fins comme la barbe ou la moustache. Du coup 28 blocs, c'est un bon équilibre entre ce que le modèle peut apprendre et le temps de calcul.

3 Question 3 : Gestion de l'over-fitting

COMMENT VOUS ÊTES-VOUS PRÉOCCUPÉ DE L'OVER-FITTING ?

Réponse :

Pour éviter l'over-fitting, on a fait plusieurs choses. D'abord, on utilise de la data augmentation : RandomHorizontalFlip avec proba 0.5, rotation de 10 degrés, et ColorJitter (brightness=0.2, contrast=0.2). Ça augmente la diversité des données sans casser les infos importantes.

Ensuite, on met de la régularisation : Dropout à 0.5 dans les couches fully connected, et Weight Decay à $1e-4$ dans l'optimizer. Ça empêche le modèle de trop mémoriser les données d'entraînement.

Pour le fine-tuning, on gèle les premières couches (stem + stage 0) qui ont des features génériques d'ImageNet. On dégèle seulement les dernières couches pour qu'elles s'adaptent à notre tâche. On utilise un learning rate assez faible ($5e-4$) pour pas tout casser.

Et finalement, on fait de l'early stopping avec patience de 5 epochs, basé sur le fairness score. On garde que le meilleur modèle selon cette métrique.

4 Question 4 : Asymétrie de la base d'apprentissage

EST-CE QUE L'ASYMÉTRIE DE LA BASE D'APPRENTISSAGE EST UN PROBLÈME ? SI OUI, COMMENT AVEZ-VOUS TRAITÉ ?

Réponse :

Oui, c'est clairement un problème. On a environ 80% d'exemples négatifs contre seulement 20% de positifs. Du coup le modèle a tendance à tout prédire négatif, ce qui donne une bonne accuracy mais c'est pas ce qu'on veut.

Pour gérer ça, on a combiné plusieurs trucs. D'abord, on utilise des class weights qui donnent plus de poids aux exemples positifs dans la loss. Ensuite, on utilise FocalLoss ou Symmetric Cross Entropy (SCE) qui s'adaptent mieux au déséquilibre en se concentrant sur les exemples difficiles. Et pour évaluer, on regarde pas juste l'accuracy globale (qui serait biaisée), mais plutôt la Balanced Accuracy et le Macro-F1 qui sont plus équitables.

5 Question 5 : Labels bruités

EST-CE QUE LE FAIT QUE LES LABELS SOIENT BRUITÉS A POSÉ PROBLÈME ? COMMENT L'AVEZ-VOUS GÉRÉ ?

Réponse :

Oui, ça pose problème. On a détecté environ 5 à 10% de labels qui sont probablement incorrects, en regardant les pertes pendant l'entraînement.

Pour gérer ça, on a fait plusieurs choses. La Symmetric Cross Entropy (SCE) combine la Cross Entropy classique et la Reverse Cross Entropy, ce qui rend le modèle plus robuste aux labels incorrects. On a aussi fait une détection automatique : on repère les exemples qui ont des pertes anormalement élevées, ce sont souvent ceux avec des labels bruités. Et le FocalLoss qu'on utilise se concentre naturellement sur les exemples difficiles, donc ça réduit l'impact des labels bruités.

6 Question 6 : Attribution du label

POUR LES IMAGES DE LA BASE DE TEST, À PARTIR DE LA SORTIE DE VOTRE RÉSEAU, COMMENT ATTRIBUEZ-VOUS LE LABEL ?

Réponse :

La méthode de base, c'est de mettre un seuil fixe à 0.5 sur la proba softmax. Si c'est au-dessus de 0.5, on met label 1, sinon -1.

Mais on a fait mieux : on utilise des seuils différents selon si c'est un homme ou une femme. Pourquoi ? Parce que le modèle se calibre pas pareil pour les deux groupes. On optimise ça sur le validation set avec une recherche par grille : le seuil pour les hommes (thresh_H) va de 0.3 à 0.8, pareil pour les femmes (thresh_F). On choisit les seuils qui maximisent la métrique $S = (\text{perf_H} + \text{perf_F})/2 - 2 \times |\text{perf_H} - \text{perf_F}|$. Cette métrique pénalise fortement les écarts entre groupes tout en gardant une bonne perf globale.

7 Question 7 : Problèmes d'équité

COMMENT AVEZ-VOUS PRIS EN COMPTE LES PROBLÈMES D'ÉQUITÉ DE L'ALGORITHME ?

Réponse :

Pour l'équité, on a fait plusieurs trucs. La métrique qu'on optimise c'est $S = (\text{perf_H} + \text{perf_F})/2 - 2 \times |\text{perf_H} - \text{perf_F}|$. Ça pénalise fortement (facteur 2) les écarts entre hommes et femmes, tout en demandant une bonne perf globale.

On a aussi implémenté une optimisation des seuils par groupe, un peu comme FairCal. Ça permet d'avoir une calibration différente pour les hommes et les femmes, ce qui compense les biais de calibration qu'on voit souvent dans les modèles.

Pendant l'entraînement, on surveille en continu perf_H , perf_F , l'écart entre les deux, et le fairness score. L'early stopping se base sur le fairness score plutôt que sur l'accuracy globale, comme ça on garde le modèle qui a le meilleur compromis perf/équité.

8 Question 8 : Caractéristiques softbio

J'AI PRÉCISÉ QUE LE LABEL CORRESPONDAIT À UNE COMBINAISON DE CARACTÉRISTIQUES « SOFTBIO » ET NON IMAGE. QU'EST-CE QUE CELA CHANGE POUR VOUS ?

Réponse :

Ça change quelques trucs dans notre approche. Pour l'architecture, un modèle générique comme ConvNeXt suffit largement. Les caractéristiques softbio (barbe, chapeau, couleur des yeux) sont visuelles, donc pas besoin d'une archi spécialisée pour la reconnaissance faciale comme ArcFace.

Pour les données, les images 80x80 ça suffit. Pas besoin de très haute résolution, on se concentre sur les détails faciaux qui nous intéressent.

Pour l'augmentation, on adapte les transformations. On limite la rotation à 10 degrés max pour garder l'orientation du visage, et on met un color jitter léger qui change pas trop la couleur des yeux (qui est importante pour le softbio).

9 Question 9 : Modèle pré-appris

AVEZ-VOUS TENTÉ D'UTILISER UN MODÈLE PRÉ-APPRIS ? QUE VOUS L'AYEZ FAIT OU NON, COMMENT PROCÉDER, CHOISIR LE MODÈLE, QU'APPRENDRE... ?

Réponse :

Oui, on a utilisé un modèle pré-entraîné : ConvNeXt-Tiny sur ImageNet, chargé avec timm.

Pourquoi ce modèle ? ConvNeXt-Tiny c'est l'état de l'art actuel et il a une taille raisonnable. On a aussi pensé à ViT-B/16 pour tester les transformers, mais on a pas eu le temps. On a évité les modèles trop gros comme ConvNeXt-Base parce qu'avec seulement 90k images, ça risquait de sur-apprendre.

Pour le fine-tuning, on gèle les premières couches (stem + stage 0) qui ont des features génériques d'ImageNet. On dégèle les dernières couches (classifier + stages finaux) pour qu'elles s'adaptent à notre tâche. On met un learning rate à $5e-4$, plus faible que pour un entraînement from scratch ($1e-3$), et on utilise un scheduler cosinus pour faire décroître le LR doucement.

Ce que le modèle apprend, c'est surtout les couches finales qui s'adaptent à la classification binaire softbio, et les stages finaux qui apprennent à détecter les détails comme la barbe, la moustache ou le chapeau.

10 Question 10 : Améliorations possibles

AVEC UN MOIS SUPPLÉMENTAIRE POUR TRAVAILLER, QUE FERIEZ-VOUS POUR AMÉLIORER VOS RÉSULTATS ?

Réponse :

Avec un mois de plus, on ferait plusieurs trucs. Pour l'architecture, on testerait ViT-B/16 avec des patches 8x8 pour capturer les micro-détails, on ferait un ensemble de modèles (ConvNeXt + ViT + EfficientNet), et on ajouterait des mécanismes d'attention pour se concentrer sur les régions faciales importantes.

Pour l'augmentation, on utiliserait des modèles de diffusion pour générer des visages équilibrés par groupe, et on développerait des techniques Mixup/CutMix plus avancées adaptées au softbio.

Pour la robustesse et l'équité, on implémenterait Group DRO pour gérer les distributions déséquilibrées, FairCal pour une meilleure calibration par groupe, et peut-être un adversarial debiasing pour réduire les biais de genre.

On explorerait aussi le semi-supervised learning avec du pseudo-labeling et du self-training itératif.

Et enfin, on améliorerait la validation avec une cross-validation stratifiée plus robuste, un vrai hyperparameter tuning (Optuna ou Ray Tune), et une analyse plus poussée des erreurs avec des matrices de confusion par groupe pour mieux comprendre où le modèle foire.

11 Question 11 : Signification du label

QUESTION NON NOTÉE : À QUOI CORRESPOND LE LABEL RECHERCHÉ ?

Réponse :

Le label correspond à une combinaison de caractéristiques « softbiométriques ». Ça inclut la présence de barbe ou moustache, la forme du menton, la couleur des yeux, la présence de chapeau/casquette, et d'autres attributs faciaux non permanents.

On pense que le label +1 correspond à la présence d'au moins N caractéristiques parmi cette liste, et le label -1 à l'absence ou la minorité de ces caractéristiques. C'est pas juste « barbe » ou « chapeau » tout seul, mais plutôt une combinaison de plusieurs attributs faciaux qui ensemble définissent la classe positive.